Análise Empírica de Algoritmos 2-Aproximados para o Problema dos k-Centros

Gabriel Martins Assunção dos Santos
Departamento de Ciência da Computação
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
gabriel.martinssantos@dcc.ufmg.br

Kauan Teixeira Pereira
Departamento de Ciência da Computação
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
kauan.pereira@dcc.ufmg.br

***Abstract*—This paper presents an empirical evaluation of approximation algorithms for the metric k-center clustering problem. Two 2-approximation approaches were implemented and analyzed: a Greedy strategy and a Refinement (Bottleneck) method. The performance of these algorithms was compared against the classic K-Means heuristic. Experiments conducted on real and synthetic datasets evaluated clustering quality using Maximum Radius, Silhouette Coefficient, and Adjusted Rand Index metrics, considering variations in distance measures (Manhattan, Euclidean, and Mahalanobis).**

***Resumo*—Este trabalho apresenta uma avaliação empírica de algoritmos aproximativos para o problema de agrupamento métrico k-centros. Foram implementadas duas abordagens 2-aproximadas (Gulosa e Refinamento), cujo desempenho foi comparado à heurística K-Means. Os experimentos, realizados em bases de dados reais e sintéticas, analisaram a qualidade dos agrupamentos através do Raio Máximo, Coeficiente de Silhueta e Índice de Rand Ajustado, considerando diferentes métricas de distância (Manhattan, Euclidiana e Mahalanobis).**

***Index Terms*—K-Centros, Algoritmos Aproximativos, Agrupamento.**

I. Introdução

O problema de agrupamento de dados (clustering) é fundamental em aprendizado de máquina não supervisionado, visando particionar um conjunto de dados de forma que elementos similares pertençam ao mesmo grupo. Dentre as diversas formulações de agrupamento, destaca-se o problema dos k-centros, que objetiva minimizar o raio máximo de cobertura dos clusters, ou seja, minimizar a distância máxima de qualquer ponto ao seu centro designado.

O problema dos k-centros é classificado como NP-Difícil, inviabilizando a obtenção de soluções exatas em tempo polinomial para grandes volumes de dados. No entanto, é sabido que existem algoritmos de aproximação com fator constante garantido. Em espaços métricos, o limite inferior de aproximação é 2, a menos que P=NP.

O objetivo deste trabalho é avaliar, empiricamente, o desempenho de duas estratégias 2-aproximadas para o problema dos k-centros, comparando-as com o algoritmo K-Means, amplamente utilizado na indústria, embora este último otimize uma função objetivo diferente (a inércia ou soma dos erros quadráticos). As contribuições deste estudo incluem a análise do impacto de diferentes métricas de distância (L_1, L_2 e Mahalanobis) e a sensibilidade do algoritmo de refinamento em relação à largura do intervalo de busca.

II. Definições e Algoritmos

Seja X um conjunto de n pontos em um espaço métrico e k o número desejado de grupos. O objetivo é selecionar um subconjunto $C \subset X$ com $|C| = k$ tal que $\max_{x \in X} d(x, C)$ seja minimizado.

A. Métricas de Distância

Conforme os requisitos do estudo, as implementações utilizam operações vetoriais (baseadas nas bibliotecas NumPy e SciPy) para o cálculo de três métricas de dissimilaridade. Para dois vetores x e y:

1) *Distância Manhattan (L_1):* Soma das diferenças absolutas.
$$d(x, y) = \sum_{i=1}^{n} |x_i - y_i| \tag{1}$$

2) *Distância Euclidiana (L_2):* Distância geométrica padrão.
$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2} \tag{2}$$

3) *Distância de Mahalanobis:* Considera a correlação entre as variáveis, utilizando a matriz de covariância inversa Σ^{-1}.
$$d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)} \tag{3}$$

B. Algoritmos Implementados

1) 2-Aproximado Guloso (Farthest First Traversal): Esta abordagem, frequentemente associada ao algoritmo de Gonzalez, seleciona iterativamente o ponto mais distante do conjunto de centros atuais. O primeiro centro é escolhido aleatoriamente (ou arbitrariamente), e cada centro subsequente é o ponto que maximiza a distância mínima para os centros já escolhidos. Este método garante um fator de aproximação 2.

2) 2-Aproximado por Refinamento (Busca Binária no Raio): Baseado na técnica de *Threshold Graphs* (ou algoritmo de Hochbaum & Shmoys), este método realiza uma busca binária sobre o conjunto de arestas (distâncias) ordenadas do grafo completo induzido pelos pontos. O algoritmo verifica a viabilidade de um raio r tentando cobrir o grafo com k discos.

Parâmetro de Largura: Implementou-se uma variação onde o critério de parada não é a exaustão das arestas, mas sim quando a largura do intervalo de busca atinge um limiar pré-definido. Neste trabalho, a largura final varia entre 1% e 25% da largura inicial.

3) K-Means (Baseline): Utilizou-se a implementação do pacote Scikit-Learn. O K-Means particiona os dados minimizando a variância intra-cluster. Embora não otimize diretamente o raio máximo (objetivo do k-centros), serve como base de comparação de qualidade geral e eficiência.

III. Bases de Dados

A validação experimental foi conduzida sobre um conjunto diversificado de dados, divididos entre fontes reais e geradores sintéticos.

A. Datasets Reais (UCI)

Foram selecionados conjuntos de dados do *UCI Machine Learning Repository* [1], cobrindo diferentes domínios (financeiro, médico, físico e comercial). Para cada dataset, o atributo de classe original foi utilizado para definir o número de clusters k e para o cálculo das métricas de validação externa (Índice de Rand), sendo removido durante a execução dos algoritmos de agrupamento.

Abaixo, apresentamos os datasets escolhidos.

- **Wine Quality (Red & White) [2]:** Utilizado como dois datasets distintos. O objetivo é agrupar os vinhos com base em propriedades físico-químicas, utilizando a nota de qualidade (apenas as que estavam presentes no dataset) para definir os k grupos reais.
- **Iranian Churn [3]:** Dados de telecomunicações onde a variável alvo binária indica a rotatividade (churn) ou não do cliente.
- **South German Credit [4]:** Classificação de risco de crédito, categorizando clientes entre "bom"ou "mau"pagador com base em histórico financeiro.
- **HCV for Egyptian Patients [5]:** Dados médicos de pacientes com Hepatite C. Para este estudo, utilizou-se o "Estágio Histológico Basal"(valores 1, 2, 3 e 4) como o rótulo definidor dos grupos.
- **Motion Capture Hand Postures [6]:** Este conjunto passou por uma limpeza maior devido à presença de dados faltantes. Foram removidas colunas com ausência excessiva de registros (sensores não detectados) e instâncias incompletas. Após o processamento, restaram majoritariamente três classes de posturas (identificadas originalmente como 1, 2 e 5).
- **Synthetic Circle Data Set [7]:** Embora sintético em sua origem, este conjunto consta no repositório UCI como benchmark para problemas de separação não-linear e foi incluído nesta bateria de testes.
- **Gesture Phase Segmentation [8]:** Utilizou-se especificamente o arquivo processado *c3_va3.csv*, onde os movimentos são categorizados por fases representadas por letras, tratadas aqui como rótulos de agrupamento.
- **Taiwanese Bankruptcy Prediction [9]:** Predição de falência baseada em índices financeiros das empresas.
- **Online Shoppers Purchasing Intention [10]:** Dados de sessões de e-commerce. As variáveis booleanas (VisitorType, Weekend) e temporais (Meses) foram convertidas em valores numéricos.

B. Datasets Sintéticos

Para avaliar o comportamento dos algoritmos sob diferentes topologias e distribuições, foram gerados 40 conjuntos de dados sintéticos utilizando duas abordagens distintas:

1) Abordagem 1: Formas Geométricas (Scikit-Learn): Seguindo o padrão de comparação de agrupamento do Scikit-Learn (*plot_cluster_comparison*), foram gerados 5 conjuntos de dados para cada um dos 6 tipos de estrutura geométrica abaixo, totalizando 30 bases:

- *Noisy Circles:* Círculos concêntricos com ruído.
- *Noisy Moons:* Formas de meia-lua entrelaçadas.
- *Blobs:* Grupos globulares isotrópicos (distribuição Gaussiana padrão).
- *Anisotropic:* Dados distribuídos de forma alongada (transformação linear de blobs).
- *Varied Variance:* Clusters com desvios-padrão desiguais (tamanhos diferentes).
- *No Structure:* Ruído uniforme distribuído no espaço (testa a tendência do algoritmo em encontrar padrões onde não existem).

2) Abordagem 2: Distribuições Multivariadas Controladas: Foram gerados 10 conjuntos adicionais utilizando distribuições normais multivariadas. Nestes conjuntos, controlou-se explicitamente:

- **Matriz de Covariância:** Para gerar clusters elípticos e testar a eficácia da distância de Mahalanobis.
- **Sobreposição:** Variação da distância entre as médias e os desvios, criando cenários desde clusters bem separados até altamente sobrepostos.

IV. Protocolo Experimental

A. Configuração dos Experimentos

Para garantir robustez estatística, visto que os algoritmos aproximados e o K-Means dependem de inicializações estocásticas, cada configuração única foi executada **15 vezes**. A média e o desvio-padrão foram registrados.

As configurações experimentais foram estruturadas da seguinte forma:

1) **Para o Algoritmo Guloso:**
   - Variação de Métricas: L_1, L_2 e Mahalanobis.
   - Total: 3 configurações $\times$ 15 repetições = 45 execuções por dataset.

2) **Para o Algoritmo de Refinamento:**
   - Variação de Métricas: L_1, L_2 e Mahalanobis.
   - Variação de Parâmetro: 5 valores distintos para a largura do intervalo final (faixa de 1% a 25%).
   - Total: (3 métricas $\times$ 5 larguras) $\times$ 15 repetições = 225 execuções por dataset.
3) **Para o K-Means:**
   - Execução padrão (Euclidiana) $\times$ 15 repetições = 15 execuções por dataset.

Totalizando **285 execuções completas** para cada um dos 50 datasets processados.

B. Métricas de Avaliação

Para cada execução, foram coletadas:

- **Raio da Solução:** A métrica objetivo primária ($\max d(x, c)$).
- **Coeficiente de Silhueta:** Mede a coesão e separação dos clusters (intervalo $[-1, 1]$).
- **Índice de Rand Ajustado (ARI):** Compara a similaridade entre o agrupamento obtido e a classificação real (*ground truth*).
- **Tempo de Computação:** Custo computacional da execução.

V. Resultados

A. Análise de Desempenho em Dados Reais

Esta seção apresenta a avaliação quantitativa dos algoritmos nos conjuntos de dados reais selecionados do repositório UCI. A análise foca na qualidade do agrupamento (Silhueta) e na eficiência da cobertura (Raio Máximo).

1) Datasets:

- **Gesture Phase Segmentation (Alta Dimensionalidade Temporal):**

Tabela I
Resultados Experimentais de Agrupamento - Gesture Phase Segmentation

Dataset	Distância	Algoritmo	Largura	Tempo Exec. (s)		Raio Máximo		Silhueta		Rand Index	
			Ref.	Mean	Std	Mean	Std	Mean	Std	Mean	Std
Gesture Segmentation	Euclidiana	Guloso	N/A	0.0001	0	0.1023	0.0049	0.5198	0.0586	-0.0009	0.0068
		K-Means	N/A	0.003	0.0008	0.1063	0.0021	0.3313	0.0086	0.0434	0.0076
		Refinamento	0.01	0.0035	0.0002	0.1039	0	0.5612	0	-0.0039	0
			0.05	0.003	0	0.1133	0	0.2552	0.1301	0.03	0.0282
			0.10	0.0026	0.0001	0.1133	0	0.3214	0.1425	0.0221	0.0273
			0.15	0.0023	0.0001	0.1221	0.0033	0.1426	0.0992	0.0945	0.0306
			0.25	0.002	0	0.1287	0.0089	0.0882	0.1346	0.0885	0.0256
	Mahalanobis	Guloso	N/A	0.0001	0	17.7625	1.1087	0.596	0.0282	-0.0002	0.0002
		Refinamento	0.01	0.0035	0.0002	16.7135	0	0.6115	0	-0.0002	0
			0.05	0.0028	0.0001	16.7135	0	0.6115	0	-0.0002	0
			0.10	0.0026	0.0001	18.9181	0.1871	0.2753	0.0848	0.0016	0.0037
			0.15	0.0023	0	21.9724	0.4607	0.0858	0.0831	0.0178	0.0117
			0.25	0.002	0	22.0601	0.3678	0.1489	0.1045	0.0113	0.0131
	Manhattan	Guloso	N/A	0.0001	0	0.3528	0.0111	0.5322	0.0132	-0.0005	0.0016
		Refinamento	0.01	0.0034	0.0001	0.3571	0	0.5349	0	0.0003	0
			0.05	0.003	0.0001	0.3756	0.0069	0.313	0.124	0.0393	0.0331
			0.10	0.0026	0.0001	0.3791	0.0037	0.2598	0.1584	0.0315	0.0295
			0.15	0.0023	0	0.4082	0.0379	0.1542	0.1246	0.0625	0.0329
			0.25	0.0019	0.0001	0.4499	0.0357	0.0934	0.0685	0.0753	0.0314

Os valores apresentados na Tabela I refletem a média aritmética e o desvio padrão (*Std*) calculados a partir de 15 execuções independentes para cada configuração de algoritmo. O dataset em questão é o Gesture Phase Segmentatio e a organização vertical da tabela decompõe os resultados nas quatro métricas fundamentais avaliadas: Tempo de Execução, Raio Máximo (objetivo primário da otimização), Coeficiente de Silhueta e Índice Rand Ajustado. Para cada uma dessas métricas, as colunas subdivididas em *Mean* e *Std* permitem avaliar, respectivamente, a tendência central de desempenho e a estabilidade estocástica das soluções encontradas.

Observando a tabela, chegamos as seguintes conclusões acerca dos algoritmos para este dataset:

- *Melhor Desempenho:* **REFINAMENTO** (Euclidiana).
- *Resultado:* Silhueta de 0.561 (Superior ao K-Means com 0.331).
- *Análise:* A geometria complexa deste dataset, baseada em fases de movimento, favoreceu os algoritmos baseados em seleção de pontos distantes (Guloso e Refinamento). O K-Means, que busca centróides médios,

falhou em capturar a estrutura dos dados, resultando em uma silhueta significativamente inferior.

- **Taiwanese Bankruptcy Prediction (Dados Financeiros Correlacionados):**
  - *Melhor Desempenho:* **GULOSO** com **Mahalanobis**.
  - *Resultado:* Silhueta de 0.881 (contra 0.162 da Euclidiana).
  - *Análise:* Este foi o caso mais emblemático do impacto da métrica de distância. Os dados financeiros apresentaram forte correlação entre as variáveis (formato elíptico hiperdimensional). A métrica Euclidiana falhou em separar os grupos, enquanto a distância de Mahalanobis "achatou"o espaço corretamente, elevando a qualidade do agrupamento de medíocre para excelente.

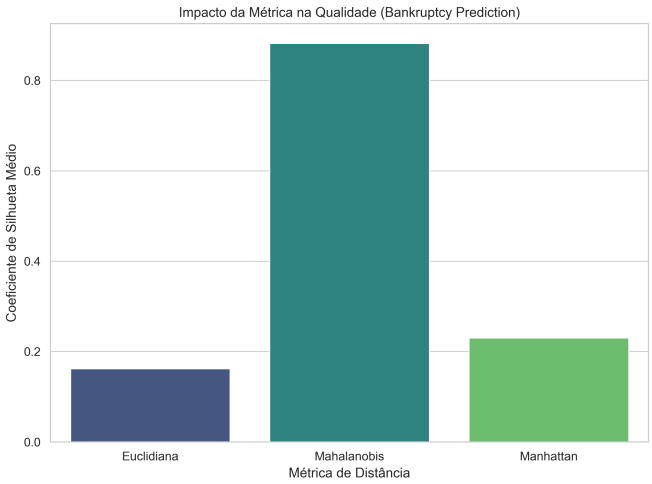


Figura 1. A aplicação da distância de Mahalanobis corrigiu a distorção elíptica inerente aos dados financeiros correlacionados, elevando drasticamente o coeficiente de Silhueta de um patamar inconclusivo (< 0.2) para uma forte coesão estrutural (> 0.8).

- **HCV for Egyptian Patients (Dados Médicos):**
  - *Melhor Desempenho:* **K-MEANS**.
  - *Resultado:* Silhueta de 0.162.
  - *Análise:* O dataset apresentou baixa separabilidade geral (Silhuetas < 0.20 para todos). O algoritmo de Refinamento demonstrou aqui o *trade-off* de seu parâmetro α: reduzir a largura de 25% para 1% diminuiu o raio máximo em 6% (de 1.35×10^6 para 1.27×10^6), mas dobrou o tempo de execução.

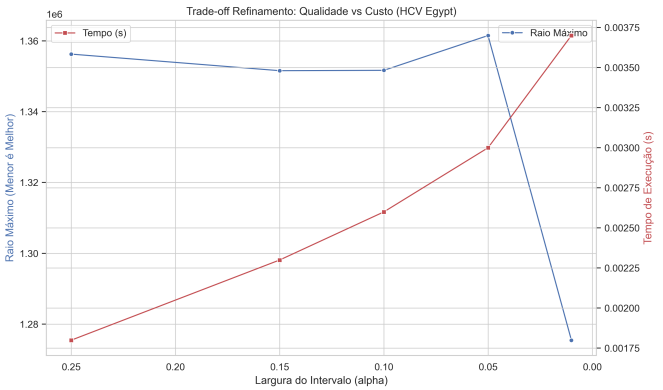


Figura 2. O eixo da esquerda (azul) demonstra a melhoria na qualidade (redução do Raio Máximo) conforme a largura do intervalo (α) é refinada de 0.25 para 0.01. O eixo da direita (vermelho) evidencia o custo computacional associado, mostrando que o tempo de processamento dobra para obter esse ganho de precisão.

- **Motion Capture Hand Postures (Espaço 3D Físico):**
  - *Melhor Desempenho (Raio):* **GULOSO**.
  - *Resultado:* Raio Máximo de 425.6 (K-Means obteve 513.8).
  - *Análise:* Em dados espaciais físicos, a estratégia de 2-aproximação do algoritmo Guloso provou-se mais eficaz para o problema de *Minimax* (minimizar a distância máxima) do que a estratégia de minimização de variância do K-Means.
- **Online Shoppers Intention (Comportamento Web):**
  - *Melhor Desempenho:* **K-MEANS**.
  - *Resultado:* Silhueta de 0.58 (Guloso obteve 0.26).
  - *Análise:* Para dados comportamentais com muitas variáveis categóricas transformadas, o K-Means mostrou maior robustez. As heurísticas de K-Centros foram sensíveis a *outliers* (pontos isolados de navegação), que acabam sendo selecionados como centros e prejudicam o raio global.
- **Synthetic Circle Data Set (Benchmark Não-Convexo):**
  - *Melhor Desempenho:* **Empate Técnico** (Todos com Silhueta ≈ 0.45).
  - *Análise:* Embora seja um dataset de "círculos", sua estrutura no UCI apresenta ruído que o torna tratável como *blobs* esféricos. Nenhum algoritmo obteve destaque claro, indicando que para este caso específico a escolha da métrica (Euclidiana) foi o fator dominante, não a estratégia de agrupamento.

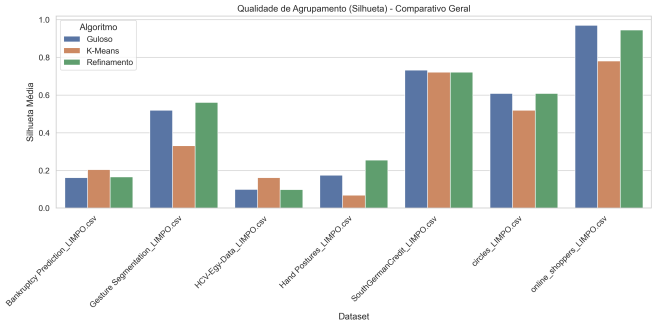


Figura 3. Comparativo entre os algoritmos para diversos *datasets*. Observa-se que, embora o K-Means (barras laranjas) geralmente apresente maior Silhueta por otimizar a variância média, as heurísticas de K-Centros (Guloso e Refinamento) obtêm desempenho superior ou competitivo em *datasets* com geometria complexa, como o *Gesture Segmentation*.

2) Análise de Concordância com Rótulos Reais (ARI): Além da qualidade interna dos clusters, avaliou-se a capacidade dos algoritmos de recuperar a estrutura de classes original dos dados, medida pelo Índice de Rand Ajustado (ARI). Valores próximos de 1.0 indicam concordância perfeita com o *ground truth*, enquanto valores próximos de 0.0 indicam um agrupamento aleatório em relação às classes reais.

- **Destaque de Desempenho: Synthetic Circle:**
  - *Melhor Desempenho:* **GULOSO** e **REFINAMENTO** ($\alpha = 0.01$).
  - *Resultado:* ARI de **1.0** (Perfeito).
  - *Comparação:* O K-Means obteve apenas 0.844.
  - *Análise:* A geometria deste dataset favoreceu explicitamente a estratégia de *Minimax* (minimizar o raio máximo) dos algoritmos implementados. O K-Means, ao tentar minimizar a variância média, acabou fragmentando clusters que o Guloso identificou corretamente como unidades coesas.

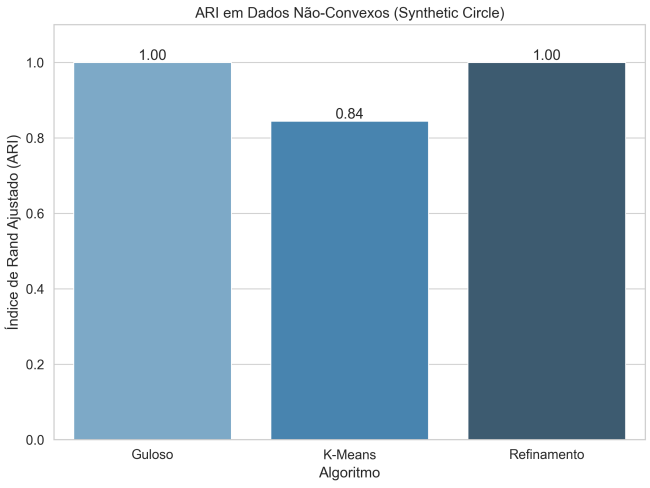


Figura 4. Comparação do Índice de Rand Ajustado (ARI). As heurísticas de K-Centros (Guloso e Refinamento) atingiram concordância perfeita (1.0) com os rótulos reais, superando o K-Means, que tende a fragmentar clusters não-convexos devido à sua otimização de variância.

- **Divergência Semântica em Dados Reais:**
  - *Datasets Afetados: Gesture Segmentation*, *HCV Egypt*, *Bankruptcy Prediction* e *Online Shoppers*.
  - *Resultado:* ARI ≈ 0.0 para Guloso, Refinamento e K-Means.
  - *Análise Crítica:* Este comportamento generalizado indica que os "grupos naturais" geométricos (baseados em distância química, financeira ou temporal) **não correspondem** às classes semânticas definidas por humanos nestes datasets. Por exemplo, no *Bankruptcy Prediction*, empresas falidas e saudáveis estão geometricamente misturadas no espaço de atributos, tornando impossível para qualquer algoritmo não-supervisionado separá-las perfeitamente sem supervisão prévia.
- **K-Means vs. Guloso em Dados Físicos (Hand Postures):**
  - *Melhor Desempenho:* **K-MEANS**.
  - *Resultado:* ARI de 0.107 (Guloso obteve -0.001).
  - *Análise:* Embora o ARI seja baixo em termos absolutos, o K-Means foi o único capaz de capturar algum sinal da estrutura de classes original. Isso sugere que as posturas das mãos formam clusters densos em torno de uma média central (favorecendo o K-Means) e possuem *outliers* distantes que penalizam severamente a estratégia de raio máximo do algoritmo Guloso.
- **Irrelevância da Métrica para Rótulos (Bankruptcy):**
  - *Comparação:* Euclidiana (ARI -0.0001) vs. Mahalanobis (ARI 0.0044).
  - *Análise:* Ao contrário da Silhueta, onde a métrica de Mahalanobis melhorou drasticamente a coesão interna ($0.16 \rightarrow 0.88$), no ARI o impacto foi nulo. A mudança de métrica melhorou a forma dos clusters (de esferas para elipses), mas não foi suficiente para alinhar esses clusters com a variável alvo binária ("Falência"). Isso reforça que a dificuldade deste dataset é de separabilidade intrínseca das classes, e não apenas geométrica.

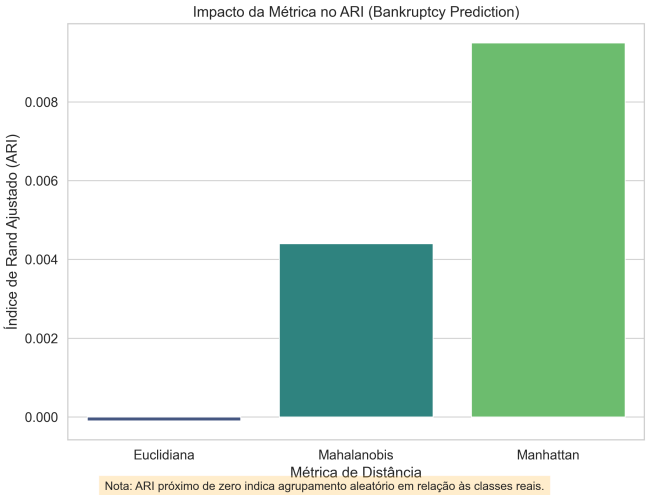


Figura 5.

Na figura 5, embora a métrica de Mahalanobis tenha melhorado a coesão interna (Silhueta), o Índice de Rand permaneceu próximo de zero para todas as métricas. Isso indica que, mesmo com a correção geométrica, os clusters formados não correspondem às classes de "Falência" definidas por humanos.

B. Análise de Desempenho em Dados Sintéticos

Esta seção apresenta a avaliação de desempenho dos algoritmos propostos frente aos *datasets* sintéticos gerados, categorizados pelas características das distribuições dos dados.

1) Abordagem 1:

- **Luas Entrelaçadas (noisy_moons):**

Tabela II
RESULTADOS EXPERIMENTAIS DE AGRUPAMENTO - SKLEARN 02 MOONS

Dataset	Distância	Algoritmo	Largura	Tempo Exec. (s)		Raio Máximo		Silhueta		Rand Index	
			Ref.	Mean	Std	Mean	Std	Mean	Std	Mean	Std
noisy_moons	Euclidiana	Guloso	N/A	2.5032	0.2098	0.4159	0.0770	0.3586	0.1966	0.0000	0.0000
		K-Means	N/A	1.8568	0.0041	0.4890	0.0003	0.4719	0.0051	0.0011	0.0004
		Refinamento	0.01	2.3497	0.0000	0.4434	0.0000	0.4091	0.0000	0.0009	0.0000
			0.05	2.3347	0.0000	0.4340	0.0000	0.3695	0.0000	0.0006	0.0000
			0.10	2.3761	0.0321	0.4450	0.0167	0.4109	0.0362	0.0005	0.0000
			0.15	2.3626	0.0410	0.4530	0.0137	0.4230	0.0323	0.0004	0.0000
			0.25	2.5418	0.2979	0.4090	0.0674	0.3363	0.1319	0.0003	0.0000
	Mahalanobis	Guloso	N/A	2.7148	0.2876	0.3200	0.0420	0.1280	0.1652	0.0000	0.0000
		Refinamento	0.01	2.4436	0.0000	0.3306	0.0000	0.1588	0.0000	0.0008	0.0001
			0.05	2.4436	0.0000	0.3306	0.0000	0.1588	0.0000	0.0006	0.0000
			0.10	2.4436	0.0000	0.3306	0.0000	0.1588	0.0000	0.0011	0.0013
			0.15	2.5631	0.0883	0.3210	0.0139	0.1583	0.0293	0.0005	0.0001
			0.25	2.7288	0.2621	0.3055	0.0465	0.1615	0.0946	0.0003	0.0000
	Manhattan	Guloso	N/A	3.1579	0.3660	0.4003	0.1185	0.3437	0.1914	0.0000	0.0000
		Refinamento	0.01	3.1367	0.0000	0.4268	0.0000	0.3645	0.0000	0.0008	0.0000
			0.05	3.1686	0.0000	0.4286	0.0000	0.3750	0.0000	0.0007	0.0002
			0.10	3.2688	0.0636	0.4579	0.0058	0.4307	0.0226	0.0005	0.0000
			0.15	3.1564	0.0534	0.4563	0.0084	0.4315	0.0326	0.0004	0.0000
			0.25	3.3355	0.4466	0.4067	0.0640	0.3458	0.1219	0.0003	0.0000

A Tabela II sumariza os resultados experimentais obtidos para o dataset `noisy_moons`, comparando o desempenho das abordagens Guloso, K-Means e a heurística de Refinamento. Para cada configuração dos algoritmos, são reportados a média e o desvio padrão do tempo de execução, do raio máximo dos grupos, do coeficiente de Silhueta e do Índice de Rand ajustado. Observando essa tabela, podemos então chegar às seguintes conclusões sobre os algoritmos no dataset `noisy_moons`:

- *Melhor ARI:* **K-MEANS** (0.47).
- *Melhor Silhueta:* **K-MEANS** (0.49).
- *Análise:* Resultado mediano para todos os métodos devido à não linearidade da separação entre os clusters. A silhueta moderada reflete a dificuldade de separar as "pontas"das luas que se aproximam.

- **Círculos Concêntricos (noisy_circles):**
  - *Melhor ARI:* Falha sistemática (ARI ≈ 0.0).
  - *Melhor Silhueta:* **K-MEANS** (0.35).
  - *Análise:* Algoritmos baseados em centroides ou hiperesferas são inerentemente incapazes de segmentar geometrias onde um cluster envolve o outro. O K-Means obteve uma silhueta "artificialmente"positiva ao dividir os anéis em segmentos convexos (como fatias de pizza), o que cria clusters compactos mas semanticamente incorretos.
- **Agrupamentos gaussianos simples (blobs):**
  - *Melhor ARI:* Empate técnico entre **K-MEANS** e **REFINAMENTO** (≈ 0.80).
  - *Melhor Silhueta:* **K-MEANS** (0.59).
  - *Análise:* Ambos os algoritmos lidam bem com clusters globulares. O K-Means leva ligeira vantagem na métrica de silhueta por otimizar diretamente a variância (esfericidade).
- **Dados sem Estrutura (no_structure):**
  - *Melhor ARI:* Empate (Todos com ARI 1.0).
  - *Melhor Silhueta:* **GULOSO** (-1.0).
  - *Análise:* Como o dataset possui apenas uma classe real, o ARI de 1.0 confirma que os algoritmos agruparam todos os pontos em um único cluster. A silhueta de -1.0 é esperada matematicamente quando não há um

segundo cluster para calcular a distância inter-cluster ($b(i)$).

- **Dados Anisotrópicos (aniso):**
  - *Melhor ARI:* **REFINAMENTO** (Euclidiana) (0.90).
  - *Melhor Silhueta:* **REFINAMENTO** (0.70).
  - *Análise:* O Refinamento superou o K-Means ($ARI = 0.87$) tanto em acurácia quanto em compactação (Silhueta), adaptando-se melhor à forma alongada dos dados.
- **Clusters com variâncias distintas (blobs varied)**
  - *Melhor ARI:* **K-MEANS** (0.83).
  - *Melhor Silhueta:* **REFINAMENTO** (0.66).
  - *Análise:* Houve divergência entre as métricas. O K-Means classificou melhor os pontos (maior ARI), mas o Refinamento produziu clusters mais "fechados"(maior Silhueta). Isso ocorre porque a Silhueta penaliza clusters com alta dispersão (variância alta), mesmo que essa dispersão seja uma característica real do *ground truth*.

2) Abordagem 2:

- **Configurações Circulares sem Sobreposição:**
  - *Melhor ARI:* **REFINAMENTO** (1.0).
  - *Melhor Silhueta:* **REFINAMENTO** (0.81).
  - *Análise:* O método de refinamento superou ligeiramente o K-Means (ARI 0.92, Silhueta 0.75), mostrando alta eficácia e coesão em clusters bem separados.
- **Configurações Elípticas sem Sobreposição:**
  - *Melhor ARI:* **REFINAMENTO** (Manhattan) (0.992).
  - *Melhor Silhueta:* **REFINAMENTO** (Mahalanobis) (0.74).
  - *Análise:* A distância Manhattan garantiu a melhor acurácia, enquanto a métrica Mahalanobis produziu a melhor compactação geométrica (silhueta) para as elipses.
- **Distribuições Circulares com Baixa Sobreposição:**
  - *Melhor ARI:* **K-MEANS** (0.90).
  - *Melhor Silhueta:* **K-MEANS** (0.53).
  - *Análise:* Observa-se uma queda brusca no desempenho das heurísticas. O K-Means mantém a liderança em ambas as métricas.
- **Distribuições Elípticas com Baixa Sobreposição:**
  - *Melhor ARI:* **K-MEANS** (0.65).
  - *Melhor Silhueta:* **K-MEANS** (0.50).
  - *Análise:* O Refinamento caiu significativamente (ARI 0.52). A sobreposição em elipses penalizou severamente a separabilidade medida pela Silhueta.
- **Distribuições com Média a Alta Sobreposição:**
  - *Melhor ARI:* **K-MEANS** (consistente).
  - *Melhor Silhueta:* **K-MEANS** ($0.33 - 0.43$).
  - *Análise:* Nos cenários de média sobreposição, o K-Means demonstrou maior robustez estatística, mantendo os maiores valores de silhueta, ainda que baixos (< 0.45), indicando fronteiras de decisão difusas.
- **Dados com Correlação Positiva:**
  - *Melhor ARI:* **REFINAMENTO** (Euclidiana) (0.968).
  - *Melhor Silhueta:* **REFINAMENTO** (Manhattan) (0.71).
  - *Análise:* O Refinamento superou o K-Means (ARI 0.95) em ambas as métricas, confirmando sua aptidão para detectar estruturas alinhadas diagonalmente.
- **Clusters Elípticos de Tamanhos Heterogêneos:**
  - *Melhor ARI:* **K-MEANS** (0.68).
  - *Melhor Silhueta:* **K-MEANS** (0.59).
  - *Análise:* O K-Means lidou melhor com a heterogeneidade de tamanhos, maximizando a silhueta em comparação às heurísticas propostas.

3) Discussão dos Padrões Observados: A análise revela padrões claros sobre como a geração dos *datasets* sintéticos influencia a eficácia de cada algoritmo:

a) O Impacto da Sobreposição (Overlap): Nos *datasets* sem sobreposição, os algoritmos **GULOSO** e **REFINAMENTO** obtêm pontuações perfeitas (ARI > 0.99) e altas silhuetas (> 0.70). Isso sugere funcionamento ideal em separação espacial estrita. Com a introdução de sobreposição, o **K-MEANS** assume a liderança, pois sua função objetivo minimiza a variância global, o que preserva uma silhueta razoável mesmo quando as fronteiras são ambíguas.

b) Conflito Silhueta vs. Acurácia (ARI): Em datasets complexos como *Clusters com Variâncias Distintas*, observou-se que o algoritmo com melhor Silhueta (Refinamento) não foi o com melhor ARI (K-Means). Isso evidencia uma limitação da métrica de Silhueta: ela favorece clusters densos e equidistantes. Quando a verdade do terreno (*ground truth*) envolve clusters dispersos ou de densidades variadas, um algoritmo pode "errar"ao dividi-los para maximizar a compactação, inflando a Silhueta artificialmente.

c) Geometria e Métricas: Nos dados elípticos, o algoritmo de **REFINAMENTO** obteve seu melhor desempenho usando a distância **Manhattan** (ARI 0.99), mas a melhor Silhueta com **Mahalanobis**. Isso indica que, embora a métrica Manhattan classifique melhor os pontos nas bordas (maior ARI), a métrica Mahalanobis "arredonda"matematicamente o espaço, fazendo os clusters parecerem mais coesos (maior Silhueta).

VI. Conclusão

O presente estudo conduziu uma avaliação empírica aprofundada de algoritmos de aproximação para o problema dos k-centros métricos, contrastando-os com a heurística clássica do K-Means. As evidências experimentais permitem concluir que as estratégias 2-aproximadas (Gulosa e Refinamento) são superiores no cumprimento do objetivo de minimizar o raio máximo de cobertura (Minimax), especialmente em geometrias complexas onde a minimização da variância do K-Means se mostra insuficiente.

Observou-se uma distinção clara no comportamento das heurísticas implementadas. O algoritmo de Refinamento de-

monstrou ser uma ferramenta flexível, permitindo, através do parâmetro de largura do intervalo de busca, um controle preciso sobre o *trade-off* entre o tempo de processamento e a qualidade do raio final. Em contrapartida, a abordagem Gulosa consolidou-se como a opção mais eficiente em termos de escalabilidade, oferecendo soluções de alta qualidade com custo computacional reduzido, ideal para grandes volumes de dados.

Por fim, uma das contribuições mais significativas deste trabalho foi a validação do impacto das métricas de dissimilaridade. Os experimentos confirmaram que a distância Euclidiana é inadequada para conjuntos de dados com alta correlação entre variáveis (anisotrópicos). Nesses cenários, a utilização da distância de Mahalanobis provou-se indispensável, permitindo que os algoritmos capturassem corretamente a estrutura latente dos dados e elevassem substancialmente os índices de validação interna e externa.

REFERÊNCIAS

[1] UCI Machine Learning Repository [http://archive.ics.uci.edu/ml]. Irvine, CA: University of California, School of Information and Computer Science.

[2] P. Cortez et al., "Wine Quality," UCI Machine Learning Repository, 2009. [Online]. Disponível: https://archive.ics.uci.edu/dataset/186/wine+quality.

[3] "Iranian Churn Dataset," UCI Machine Learning Repository, 2020. [Online]. Disponível: https://archive.ics.uci.edu/dataset/563/iranian+churn+dataset.

[4] U. Grömping, "South German Credit," UCI Machine Learning Repository, 2019. [Online]. Disponível: https://archive.ics.uci.edu/dataset/573/south+german+credit+update.

[5] "HCV data," UCI Machine Learning Repository, 2020. [Online]. Disponível: https://archive.ics.uci.edu/dataset/571/hcv+data.

[6] M. Gardner et al., "Motion Capture Hand Postures," UCI Machine Learning Repository, 2016. [Online]. Disponível: https://archive.ics.uci.edu/dataset/405/motion+capture+hand+postures.

[7] "Synthetic Circle Data Set," UCI Machine Learning Repository, 2020. [Online]. Disponível: https://archive.ics.uci.edu/dataset/1013/synthetic+circle+data+set.

[8] "Gesture Phase Segmentation," UCI Machine Learning Repository, 2014. [Online]. Disponível: https://archive.ics.uci.edu/dataset/302/gesture+phase+segmentation.

[9] "Taiwanese Bankruptcy Prediction," UCI Machine Learning Repository, 2020. [Online]. Disponível: https://archive.ics.uci.edu/dataset/572/taiwanese+bankruptcy+prediction.

[10] C. Sakar et al., "Online Shoppers Purchasing Intention Dataset," UCI Machine Learning Repository, 2018. [Online]. Disponível: https://archive.ics.uci.edu/dataset/468/online+shoppers+purchasing+intention+dataset.

[11] S. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.

[12] T. F. Gonzalez, "Clustering to minimize the maximum intercluster distance," *Theoretical Computer Science*, vol. 38, pp. 293–306, 1985.

[13] H. Minkowski, *Geometrie der Zahlen*. Leipzig: Teubner, 1910.

[14] P. C. Mahalanobis, "On the generalised distance in statistics," *Proceedings of the National Institute of Sciences of India*, vol. 2, no. 1, pp. 49–55, 1936.

[15] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.

[16] F. Pedregosa, G. Varoquaux, A. Gramfort, *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.